

1 Сколько GPU у OpenAI и Anthropic?

на 22.09.2026

Простой ответ по состоянию на 22 сентября 2026 года

OpenAI

~0,5 млн GPU

к концу 2026 года — около миллиона [1]

- Сейчас в работе 150–200 тыс. видеокарт [2]
- GPT-6 обучали сразу на 100+ тыс. GPU [3]
- Ещё 400 тыс. видеокарт на подходе [4]

как делятся между задачами — не раскрывают [10]

Anthropic

>1,3 млн чипов

примерно в 2–3 раза больше, чем у OpenAI

- Свыше 1 млн чипов Amazon (Trainium2) [5]
- Плюс ~325 тыс. GPU в аренде у xAI [6][7]
- Плюс чипы Google (TPU) [8]

как делятся между задачами — не раскрывают [10]

На что компании тратят мощности (оценка на конец 2026) [9]:

Обучение моделей ~62%

Ответы пользователям ~38%

Компании не публикуют точную разбивку; ещё в 2024 на обучение уходило 67% — теперь мощности ушли в доводку и ответы [9][10]

Коротко: у OpenAI около полумиллиона GPU (к концу года — миллион), у Anthropic около 1,3 млн чипов. Треть мощностей — ответы пользователям, остальное — обучение и доводка моделей.

[1] Epoch AI / stargate.how, 18.09.26 · [2] Presenc AI / TechTimes, 20.09.26 · [3] Axios, 03.09.26 · [4] NVIDIA / Дж. Хуанг, 06–07.09.26 · [5] Waystar Analysis, 11.05.26 · [6] Measured AI, 25.06.26 · [7] Creeta, 28.05.26 · [8] Dev.to, 07.04.26 · [9] FourWeekMBA, 14.09.26 · [10] ITK Services, 11.05.26 · полный список — в sources_slide1.md

2 Маржа Sail Research на GLM 5.3

на 22.09.2026

Вводные данные по модели GLM 5.3

753 млрд параметров · ~40 млрд активных · тариф ASAP с прайса Sail [6] · курс ЦБ РФ 84,10 ₽/\$ [9]

ЦЕНА ДЛЯ КЛИЕНТА

1

82 ₽ и 259 ₽

82 ₽ за 1 млн входных токенов и 259
₽ за 1 млн выходных токенов [6]

ВЫРУЧКА

2

127 ₽

за 1 млн токенов при соотношении 3
к 1: 75% входных + 25% выходных

АРЕНДА УЗЛА 8 × H200

3

≈2 200 ₽/час

средняя аренда: 275 ₽ за GPU-час × 8
GPU в узле [8]

ПОРОГ ОКУПАЕМОСТИ

4

≈4 836 ток/с

ниже этой скорости — минус, выше
— зарабатывают

Маржа при разной загрузке узла (расчёт по средней аренде 275 ₽ за GPU-час) [8]:

4 000 ток/с

-21%

ниже порога окупаемости

7 000 ток/с

+31%

типичная загрузка с батчингом

10 000 ток/с

+52%

хорошая утилизация узла

Ответ: Sail Research предположительно продаёт GLM 5.3 с маржой +31% —
при типичной загрузке узла 7 000 ток/с; выше 10 000 ток/с маржа растёт до +52%, ниже ~4 800 ток/с — убыток.

[6] Sail / Pricing, 22.09.26 · [7] Z.ai / Hugging Face, GLM-5.3 · [8] Simplismart, 08-09.26 (H200: \$2.60–3.95/GPU-ч, средняя ~275 ₽) · [9] Банк России / курс на 22.09.26 · GLM-5.2 у Sail ранее: \$0.80 / \$3.00 за 1 млн токенов (Requesty, 21.09.26). Суммы округлены, расчёт — в коде.